



# **UNIVERSIDAD NACIONAL DEL ALTIPLANO**

**FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA,  
ELECTRÓNICA Y SISTEMAS**

**ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS**

## **ALGORITMOS GENÉTICOS EN APRENDIZAJE DE MÁQUINA**

**ACTIVIDAD 02 - RESUMEN EJECUTIVO**

### **INFORMACIÓN GENERAL**

**CURSO: APRENDIZAJE DE MAQUINA**

**RESPONSABLE DE ASIGNATURA:**

**FERNANDEZ CHAMBI MAYENKA**

**PRESENTADO POR:**

Miguel Angel Llusca Surco

Cristian Junion Cunurana Calderon

Paolo Boris Luna Luque

Ludwin Riva Ticona

---

---

**PUNO, PERÚ**

**2026**

# Algoritmos genéticos en aprendizaje de máquina

Resumen ejecutivo | Tres ejemplos ejecutables, un mismo ciclo evolutivo

## Objetivo y trabajo realizado

Se implementaron y verificaron tres aplicaciones de algoritmos genéticos (AG): selección de características, optimización de hiperparámetros y búsqueda de arquitectura neuronal. Se revisaron dos cuadernos existentes, se creó el ejemplo faltante de selección de características y se documentó la ejecución en un README. Cada cuaderno contiene código, explicación, gráficos y resultados exportables.

## Tres aplicaciones

**01. Selección de características.** Sobre Wine (178 observaciones, 13 variables y 3 clases), un cromosoma binario elige las entradas de una regresión logística. La aptitud combina exactitud de validación cruzada y una penalización de 0.02 por la fracción de variables utilizadas. Se comparó con el mismo modelo usando las 13 variables.

**02. Hiperparámetros.** Sobre Wine, un AG busca cinco parámetros de Random Forest: número de árboles, profundidad, mínimo de muestras para dividir, variables por división y criterio. La aptitud es la exactitud media de validación cruzada; la referencia es un Random Forest con parámetros predeterminados.

**03. Neuroevolución.** Sobre 300 puntos sintéticos con etiqueta  $x_1 \times x_2 > 0$ , se evoluciona una red de una o dos capas ocultas y activación ReLU o tanh. El AG elige arquitectura; MLPClassifier entrena los pesos con L-BFGS. La referencia es una capa de cuatro neuronas con tanh.

## Método y evaluación

Los tres ejemplos explicitan representación, inicialización, aptitud, selección, cruzamiento, mutación y terminación. Se conservan dos élites. Las poblaciones son de 16, 10 y 8 individuos, con 10, 6 y 10 generaciones, respectivamente. Las semillas son 42 para los dos casos Wine y 10 para la red neuronal.

Wine se separa en 142 muestras de desarrollo y 36 de prueba; la selección usa CV estratificada de tres pliegues. La red utiliza 180 muestras de entrenamiento, 60 de validación y 60 de prueba. El test permanece fuera de la búsqueda; al final se reentrenan los modelos sobre todo desarrollo y se comparan con su referencia.

## Código, cuadernos y documentación

**GitHub: Miguel7293 / Algoritmos-gen-ticos-Actividad-02-**

<https://github.com/Miguel7293/Algoritmos-gen-ticos-Actividad-02->

El README contiene enlaces directos para abrir los tres cuadernos en Google Colab, instrucciones y evidencias de ejecución.

# Resultados verificados

Exactitud (%) de los modelos de referencia y de las soluciones seleccionadas.

| Ejemplo         | Referencia<br>CV / val. | AG<br>CV / val. | Referencia<br>prueba | AG<br>prueba |
|-----------------|-------------------------|-----------------|----------------------|--------------|
| Características | 97.19 %                 | 100.00 %        | 97.22 %              | 97.22 %      |
| Hiperparámetros | 95.11 %                 | 95.80 %         | 100.00 %             | 100.00 %     |
| Neuroevolución  | 98.33 %                 | 100.00 %        | 96.67 %              | 100.00 %     |

CV / val. es la métrica usada para seleccionar candidatos; prueba es una evaluación independiente. En características se muestra exactitud, no el fitness penalizado. Las tareas son distintas: estos valores no permiten ordenar los tres métodos entre sí.

## Hallazgos principales

**Características:** se conservaron 7 de 13 variables (alcohol, ash, alkalinity\_of\_ash, flavanoids, color\_intensity, hue, proline). La aptitud penalizada fue 0.9892. El cambio de exactitud en prueba frente a usar todas las variables fue de +0.00 puntos porcentuales.

**Hiperparámetros:** el ganador utilizó 80 árboles, profundidad 12, mínimo de división 3, max\_features=log2 y criterio entropy. El cambio en prueba fue de +0.00 puntos porcentuales.

**Neuroevolución:** se eligieron capas ocultas [8, 2] con activación relu; se evaluaron 14 de las 18 arquitecturas posibles. El cambio en prueba fue de +3.33 puntos porcentuales. Se registraron 0 advertencias de convergencia durante la búsqueda y 0 en los ajustes finales.

## Revisión y alcance de las conclusiones

Los tres cuadernos se ejecutaron completos en kernels nuevos de Jupyter, sin errores y con gráficos guardados. Se verificaron particiones independientes y conservación del mejor fitness por elitismo. Se corrigieron la ausencia de test en los ejemplos originales, el registro incompleto de la última generación de neuroevolución y la falta de una referencia de comparación.

Los ejemplos muestran cómo un AG busca soluciones, pero no garantizan mejor exactitud en prueba ni el óptimo global. Los datos son pequeños y se emplea una semilla por caso. La validación reutilizada durante la búsqueda puede sobreestimar el rendimiento. Para conclusiones generales harían falta varias particiones y semillas, además de comparar con búsqueda aleatoria o exhaustiva.

## Trazabilidad y fuentes

Entorno verificado: Python 3.11.7, NumPy 2.4.6, scikit-learn 1.9.1 y Matplotlib 3.11.2. Las métricas e historiales están en resultados/\*.json; los HTML del repositorio son material complementario con ejemplos propios.

Fuentes: consigna Actividad 02; scikit-learn: [validación cruzada](#); Wine; MLPClassifier.